

Quanto custa manter a solução completa?

Orçamento para a central omnichannel própria e o chatbot que analisa **todos os tickets**, responde quando possui dados confiáveis e transfere os demais com contexto.

OPERAÇÃO RECORRENTE

R\$ 836,79/mês

R\$ 10.041,44 por ano

COM RESERVA DE CANAIS

R\$ 1.036,79/mês

R\$ 12.441,44 por ano

Componente recorrente	Mensal	Anual
IA — 5 chamadas em 100% dos tickets	R\$ 34,17	R\$ 410,06
Servidor 8 GB / 4 vCPU	R\$ 247,56	R\$ 2.970,72
Backup diário	R\$ 74,27	R\$ 891,22
Anexos em object storage	R\$ 25,79	R\$ 309,45
Domínio	R\$ 5,00	R\$ 60,00
Manutenção — 3h × R\$ 150	R\$ 450,00	R\$ 5.400,00
TOTAL BASE	R\$ 836,79	R\$ 10.041,44

O total não inclui valores ainda sem tarifa pública: contrato da RA API, mensagens pagas do WhatsApp fora da janela de atendimento, impostos e eventual criação de uma API de pedidos. A reserva opcional de R\$ 200/mês serve para planejamento e deve ser substituída pelas faturas reais.

O custo de implementação aparece somente na página 4 e não integra os totais recorrentes.

100% dos tickets passam pela primeira análise

A primeira chamada identifica assunto, risco e rota. As seguintes coletam dados, consultam registros e respondem. Quando a solução não consegue concluir, gera o resumo e encaminha ao humano.

Chamada	Entrada estimada	Saída média
1 · triagem e primeira resposta	1.000 tokens	250 tokens
2 · coleta de informação	1.500 tokens	250 tokens
3 · resposta após consulta	2.000 tokens	250 tokens
4 · confirmação ou handoff	2.500 tokens	250 tokens
5 · interação adicional	3.000 tokens	250 tokens

Custo = [(tokens de entrada × US\$ 0,40) + (tokens de saída × US\$ 1,60)] ÷ 1 milhão × R\$ 5,1575

Cenário	Entrada/mês	Saída/mês	Mensal	Anual
4 chamadas médias	7.729.838	1.104.262	R\$ 25,06	R\$ 300,71
5 chamadas médias · adotado	11.042.625	1.380.328	R\$ 34,17	R\$ 410,06
5 chamadas no teto de 420 tokens	11.042.625	2.318.951	R\$ 41,92	R\$ 503,00
5 chamadas e volume dobrado	22.085.250	2.760.656	R\$ 68,34	R\$ 820,11

Premissas

- 1.003,875 tickets/mês.
- 100% passam pela IA.
- 10% de repetição/reenvio.
- Sem desconto de cache.
- 250 tokens médios; o protótipo permite até 420.

Controles necessários

- Registrar tokens reais por chamada.
- Limitar chamadas e custo por ticket.
- Resumir histórico crescente.
- Não chamar a IA após handoff.
- Usar regras para ações críticas.

O que precisa estar contratado ou disponível

Bloco	Requisito para funcionar	Tratamento no orçamento
Aplicação e banco	VM Linux, PostgreSQL, Redis/worker, HTTPS e gestão de segredos.	R\$ 247,56/mês
Continuidade	Backup diário com restauração testada, logs e alertas.	R\$ 74,27/mês
Anexos	Object storage para imagens e documentos.	R\$ 25,79/mês
Canal Vértice	Widget/formulário integrado ao backend.	Incluído na infraestrutura
E-mail	Caixa corporativa, threading e envio transacional.	R\$ 0 se reutilizar a conta; plano Pro opcional
WhatsApp	Conta Meta, número habilitado, webhook e templates aprovados.	Atendimento iniciado pelo cliente: R\$ 0 na janela; demais mensagens variáveis
Reclame Aqui	Contrato RA API, credenciais, leitura, resposta e conciliação.	Sob consulta; fora do total
Pedidos/rastreio	API autorizada ou serviço interno com identidade do cliente.	Pressupõe API existente

Orçamentos que não devem ser somados

Forma de implantação	Mensal	Anual	Uso
Chatbot isolado	R\$ 650,09	R\$ 7.801,02	Pressupõe central já existente
Omnichannel isolado	R\$ 802,62	R\$ 9.631,39	Sem consumo de IA
Solução conjunta recomendada	R\$ 836,79	R\$ 10.041,44	Compartilha servidor, domínio e manutenção

WhatsApp: mensagens de serviço dentro da janela de 24 horas aberta pelo cliente são gratuitas. Templates iniciados pela empresa e mensagens fora das condições gratuitas dependem da categoria e do mercado. **Reclame Aqui:** a API permite ler e responder no sistema próprio, mas a contratação é comercial e não possui preço público encontrado.

Fontes: [DigitalOcean](#) · [servidor](#), [backup](#), [storage](#), [WhatsApp](#), [RA API](#) e [Resend](#). Alta disponibilidade, plantão 24x7, telefonia e migração histórica extensa exigem outro dimensionamento.

Implementação não entra no custo mensal

Estimativa para transformar o protótipo local em um MVP operacional. A manutenção recorrente permanece em 3 horas/mês a R\$ 150/h; a implantação usa a premissa de equipe técnica a R\$ 200/h.

Entrega	Horas	Custo
Requisitos, dados, canais e critérios de aceite	16	R\$ 3.200,00
Backend, banco PostgreSQL, mensagens, anexos e histórico	32	R\$ 6.400,00
Perfis, permissões, LGPD e trilha de auditoria	20	R\$ 4.000,00
Ranking 40/40/20, fila-2.0, P0 e explicabilidade	24	R\$ 4.800,00
Canal Vértice, e-mail e WhatsApp	36	R\$ 7.200,00
Chatbot, prompts, RAG e consulta de pedidos	32	R\$ 6.400,00
Logs, tokens, alertas, backup e restauração	20	R\$ 4.000,00
Testes ponta a ponta, segurança e correções	28	R\$ 5.600,00
Treinamento e entrada assistida	16	R\$ 3.200,00
TOTAL BASE	224	R\$ 44.800,00
Contingência de planejamento · 20%	44,8	R\$ 8.960,00
RESERVA TOTAL	268,8	R\$ 53.760,00

Integração Reclame Aqui: após contratação e acesso técnico, reservar mais 24–48 horas, ou R\$ 4.800,00–R\$ 9.600,00, antes da contingência. O contrato RA API continua fora desse valor.

O orçamento pressupõe API de pedidos já existente, um ambiente de produção, integrações sem migração histórica massiva e entrada assistida em horário comercial.

Os dois rankings ainda não estão ativos

RESULTADO DA VERIFICAÇÃO

O protótipo final não calcula 40/40/20 nem fila-2.0.

```
{table(["Regra esperada", "Fórmula", "Situação encontrada"], [ ["Ranking por assunto · 40/40/20", "40% retenção + 40% necessidade humana + 20% insatisfação", "Ausente; há scores fixos por categoria"], ["Fila individual · fila-2.0", "30% prazo + 25% impacto + 25% retenção + 10% recontato + 10% espera", "Ausente; a fila ordena o score fixo"], ["Exceção crítica", "P0 prevalece sobre o score", "Presente para fraude/cobrança"], ]]}
```

Evidência no código

- `app/domain.py` atribui valores fixos como 100, 86, 78, 72, 22 e 8.
- `app/service.py` grava diretamente `rule["score"]` e `rule["priority"]`.
- `app/database.py` ordena P0–P3 e depois o campo `score`, sem guardar componentes ou versão da fórmula.
- O prompt diz que o servidor calcula o score, mas isso não implementa as duas fórmulas.

Correção necessária antes do piloto

1. Calcular 40/40/20 por assunto com métricas aprovadas e versionadas.
2. Calcular fila-2.0 por ticket com prazo, impacto, retenção, recontato e espera.
3. Preservar P0 para sinais críticos.
4. Salvar os cinco componentes, score, regra e data para explicar a posição.
5. Usar a IA apenas para extrair sinais; o servidor valida e calcula.

Consequência: os custos desta análise continuam válidos, mas a proposta de priorização ainda precisa ser implementada no protótipo final para que a demonstração corresponda à solução documentada.